

Verificado con la documentación oficial

8 hábitos que te bajan el gasto de tokens en Claude

Circulan 17 consejos. Cinco no se sostienen y uno es falso.



1

Lo repetido puede costar diez veces menos

Si mandás el mismo contexto fijo una y otra vez, se puede cachear. Las lecturas de caché cuestan alrededor de una décima parte del precio normal de entrada.

2

Una página de PDF paga dos veces

Entre 1.500 y 3.000 tokens por página según la densidad. Y como cada página además se convierte en imagen, encima paga tokens de imagen. Pegá el texto y subilo como .md.

3

1296 tokens, o 64

Claude mide las imágenes en bloques de 28 por 28 píxeles. Una captura de 1000x1000 son 1296 tokens. El recorte de 200x200 que de verdad importa, 64.

4

Opus cuesta cinco veces lo que Haiku

5 contra 1 dólar por millón de tokens de entrada, y 25 contra 5 de salida. Para clasificar, extraer datos o resumir, Haiku alcanza y sobra.

5

Cada mensaje relee toda la conversación

El modelo no tiene memoria entre turnos: en cada mensaje se reenvía el historial completo. En el mensaje 40 estás pagando los 39 anteriores otra vez.

6

Cinco mensajes cuestan cinco veces

Partir una misma tarea en cinco mensajes multiplica por cinco el contexto reenviado. Escribí el pedido completo de una sola vez.

7

Subilo una vez, referencialo siempre

Un archivo subido una vez y referenciado pesa una vez.
El mismo archivo pegado en cada turno pesa en cada
turno, y crece con la conversación.

8

Gastan antes de que escribas nada

Las definiciones de las herramientas se cargan al principio del contexto, antes que tu mensaje. Dejá activas solo las que vas a usar en esa tarea.

"Escribí prompts de menos de 30 palabras"

La documentación oficial de prompting dice lo contrario: conviene dar más contexto del que parece necesario. Los prompts cortos producen respuestas genéricas, y después las regenerás.

El detalle de los ocho, con las fuentes, en cluna.ar